

Marc Soler Aguirre

Data Scientist | NLP y modelos de lenguaje

Barcelona · marc.soler@correo-ficticio.es · 600 000 002

PERFIL

Científico de datos con cuatro años de experiencia en proyectos de procesamiento de lenguaje natural. Trabajo habitual con embeddings, clasificación de texto y sistemas de recuperación semántica. Me muevo con soltura entre la fase de experimentación y la de puesta en producción, y defiendo que un modelo que nadie puede explicar no llega a usarse.

EXPERIENCIA

Data Scientist en Sanitas Digital (2023-2026). Modelos de clasificación automática de informes clínicos con transformers afinados sobre corpus propio, que redujeron el tiempo de triaje documental de doce minutos a menos de dos por informe. Implementación de un buscador semántico sobre el histórico documental usando sentence-transformers y similitud coseno, con evaluación por recall en los primeros diez resultados. Diseño del protocolo de anotación y coordinación de tres anotadores clínicos. Analista de datos en Idealista (2022-2023). Segmentación de usuarios y modelos de propensión al contacto con scikit-learn. Análisis de cohortes y diseño de test A/B para el buscador de vivienda. Investigador en prácticas en el Barcelona Supercomputing Center (2021-2022). Evaluación de modelos de lenguaje en castellano y catalán.

PROYECTOS

Detector de duplicados semánticos en anuncios inmobiliarios: vectorización del texto, agrupamiento por umbral de coseno y revisión manual de la frontera de decisión. Detectó un ocho por ciento de anuncios repetidos que los filtros por palabras clave no encontraban. Publicación en el congreso SEPLN sobre desambiguación de siglas médicas.

TECNOLOGÍAS

Python, pandas, numpy, scikit-learn, PyTorch, Hugging Face Transformers, sentence-transformers, spaCy, SQL, MLflow, Weights & Biases, Docker, FastAPI para servir modelos, Jupyter.

FORMACIÓN

Máster en Ciencia de Datos, Universitat de Barcelona (2020-2022). Grado en Matemáticas, Universitat Autònoma de Barcelona (2016-2020).

LOGROS

Reducción del coste de anotación manual a la mitad mediante aprendizaje activo: el modelo propone los casos dudosos y el equipo clínico solo revisa esos, en lugar de muestrear al azar. Establecimiento del protocolo de evaluación de modelos de la unidad, con conjunto de control congelado y revisión obligatoria de sesgos por grupo demográfico antes de cualquier promoción a producción. Formación interna sobre embeddings y búsqueda vectorial para el equipo de producto, con material propio que se sigue usando.

PUBLICACIONES Y DIVULGACIÓN

Ponencia en el congreso SEPLN 2024 sobre desambiguación de siglas médicas en informes de alta. Artículo divulgativo sobre evaluación de buscadores semánticos en el blog de ingeniería de la empresa. Colaborador ocasional en un grupo de lectura de artículos de procesamiento de lenguaje natural.

OTROS DATOS

Disponibilidad inmediata. Preferencia por modelo híbrido en Barcelona o remoto con visitas periódicas. Interés declarado en puestos donde el modelo llegue a producción y no se quede en prueba de concepto.

IDIOMAS

Español y catalán nativos. Inglés C1. Francés B1.